

# Arquitetura Baseada em Fonte de Verdade Paralela para Geração de Fingerprint Físico-Operacional em Sistemas Industriais Legados

Emilio Bresolin

Programa de Pós-Graduação em Ciência da Computação, PUCRS

Orientador: Prof. Dr. Fabiano Passuelo Hessel

*Seminário de Andamento, 2026*

## Resumo

Sistemas industriais legados dependem da integridade das medições usadas por PLCs e sistemas SCADA. Ataques de injeção de dados falsos, repetição de leituras válidas anteriormente (replay attack) e alteração gradual podem modificar a representação digital sem modificar o fenômeno observado pelo sensor. Este trabalho propõe uma Fonte de Verdade Física Paralela: uma cópia do sinal de campo é enviada para um Edge Gateway e compartilhada com os outros Edge Gateways que fazem parte do sistema. Os Edges Gateways validam o valor do sinal por consenso, e o valor consensuado é comparado com o valor armazenado pelo sistema SCADA. Caso os valores sejam aceitos como verdadeiros, estes são armazenados e organizados em janelas temporais para gerar um fingerprint do comportamento do processo. O Seminário de Andamento apresenta um protótipo acadêmico funcional, executado em ambiente controlado. Por escolha metodológica, o compressor, os sensores, o PLC e o SCADA são simulados, pois representam os equipamentos de uma planta industrial. Mesmo com esses componentes simulados, o protótipo executa todo o fluxo proposto: recebe as leituras dos sensores, realiza a comunicação por MQTT, consulta os dados do SCADA por OPC UA, executa o consenso distribuído com CometBFT, aplica as regras de confiança e exclusão por meio da aplicação ABCI, compara o estado físico consensado com o estado informado pelo SCADA e armazena os resultados validados no MinIO. Esses dados também são utilizados na formação do dataset processado pelos modelos de aprendizado de máquina. Portanto, a simulação está nos equipamentos industriais, enquanto o funcionamento da arquitetura é executado pelo protótipo. O protótipo demonstrou o caminho normal, o bloqueio por perda de quórum e o bloqueio por divergência entre o estado físico consensuado e o SCADA. No cenário normal, os Edge Gateways obtiveram score de confiança 1,000. Na perda de quórum, os scores foram 0,298, 0,233 e 0,210, e nenhum estado foi aceito. A avaliação preliminar com o dataset público ADFA-LD obteve macro F1 de 0,9187 e acurácia de 0,9229 no melhor modelo LSTM. O trabalho também gera um dataset físico-operacional, na medida que o sistema é executado. A continuidade prevê ampliar a quantidade de dados utilizados para validar a solução proposta através do uso de outros datasets públicos, e repetir os experimentos para fortalecer a análise acadêmica.

**Palavras-chave:** *IDS industrial; Edge Computing; SCADA; sistemas industriais legados; consenso; fingerprint operacional; LSTM; GRU.*

## I. Introdução

Nos sistemas de automação e controle industrial, a percepção do ambiente operacional baseia-se na atuação de sensores de campo. Tais dispositivos mensuram variáveis contínuas do processo como temperatura, pressão e rotação, gerando grandezas numéricas denominadas, no escopo deste trabalho, de valores de processo. Esses valores são enviados ao Controlador Lógico Programável (PLC), que executa a lógica de controle local. Em um nível de abstração superior, o sistema SCADA (*Supervisory Control and Data Acquisition*) consolida as informações provenientes dos PLCs, viabilizando a supervisão operacional, o registro de histórico, a gestão de alarmes e a interface com o operador. A partir dessa arquitetura, define-se como estado físico o conjunto de valores e metadados que descreve o equipamento em um instante específico, ao passo que o agregamento de dados disponibilizado concorrentemente pelas camadas de controle (PLC) e supervisão (SCADA) passa a constituir o domínio lógico do sistema.

O problema estudado aparece quando o domínio lógico apresenta valores plausíveis, mas diferentes do estado físico. Botvinkin et al., no artigo sobre classificação e detecção de ataques em redes de sensores ligadas a sistemas SCADA [1], descrevem ataques que exploram a comunicação e a confiança nos dados recebidos. Entre os comportamentos considerados neste trabalho estão a injeção de dados falsos, a repetição de mensagens antigas e a alteração gradual de valores. Sistemas de Detecção de Intrusão (IDS), centrados exclusivamente no monitoramento de pacotes de rede, *logs* ou dados previamente digitalizados, correm o risco de receber a informação após a realização de uma manipulação indevida. Essa situação causa uma falha de segurança pela falta de uma referência independente que permita averiguar a integridade do dado físico antes de sua entrada no PLC.

A Figura 1 ilustra o fluxo da informação desde a sua origem nos sensores de campo, passando pelo processamento no PLC e pela transmissão via rede industrial, até o seu destino no sistema supervisório. Na representação, o nível de chão de fábrica (sensores e PLC) posiciona-se à esquerda, o meio de comunicação (rede industrial) ao centro, e o nível de supervisão (SCADA e estações de operação) à direita. A Figura 1 ainda destaca, na rede e no SCADA, os pontos vulneráveis a alterações ou repetições de dados (*Attacker*), evidenciando a principal fragilidade dessa arquitetura: a ausência de uma segunda leitura do sinal de campo para fins de validação e comparação com o valor exibido ao operador.




Figura 1. Caminho tradicional entre sensores, PLC, rede industrial e SCADA, sem uma fonte paralela para verificar o valor físico. Fonte: elaboração do autor para este projeto de pesquisa.

Considerando este contexto, a pergunta de pesquisa deste trabalho é: como construir uma fonte físico-operacional paralela, não intrusiva e distribuída, capaz de apoiar a detecção de alterações silenciosas em sistemas industriais legados?

A proposta deste projeto consiste em observar uma cópia do sinal antes do PLC, reunir as observações em Edge Gateways, validar o conjunto de leituras e comparar o resultado com o domínio lógico. As seções seguintes detalham cada etapa, informam o que foi simulado, identificam as tecnologias executadas e apresentam os resultados produzidos até este momento.

**Contribuições desta etapa.** Este trabalho apresenta: (1) um protótipo funcional e auditável; (2) a execução completa de cinco etapas, da geração dos sinais ao fingerprint; (3) três cenários com decisões, leituras e scores registrados; (4) um dataset físico-operacional gerado automaticamente; e (5) uma avaliação preliminar de modelos LSTM e GRU com métricas. O ambiente físico simulado é parte do método e permite controlar as condições, repetir cenários e observar o efeito de cada alteração, enquanto as tecnologias de comunicação, consenso, armazenamento e aprendizado funcionam de forma real.

## II. Fundamentação e Trabalhos Relacionados

### II-A. Conceitos Básicos

No contexto deste trabalho, o *pipeline* é definido como a sequência encadeada de etapas de processamento executadas sobre os dados. Esse fluxo inicia na leitura dos sinais dos sensores (dados de processo), prossegue com o compartilhamento entre *Edge Gateways*, o mecanismo de consenso e a verificação cruzada com o sistema SCADA, e termina no armazenamento, na estruturação de janelas temporais e na alimentação do modelo de aprendizado de máquina. Uma janela temporal é um agrupamento ordenado de estados sucessivos, conceito que habilita o modelo a analisar não apenas leituras pontuais, mas também a dinâmica temporal e a evolução dos valores ao longo do tempo.

A partir dessa estruturação temporal, os modelos de aprendizado de máquina passam a atuar diretamente sobre os conjuntos de dados para inferir o perfil comportamental de cada dispositivo. Para essa finalidade, forma utilizadas as redes neurais recorrentes *Long Short-Term Memory* (LSTM) e *Gated Recurrent Unit* (GRU), cuja capacidade de reter a memória de amostras anteriores as torna especialmente adequadas para

o processamento de dados sequenciais. Ao mapear essa dinâmica ao longo dos intervalos, o modelo estabelece o fingerprint físico-operacional, isto é, a assinatura do comportamento esperado do equipamento. Cabe ressaltar que o fingerprint não substitui o protocolo de consenso, mas o complementa: enquanto o consenso determina pontualmente se o estado físico de uma única rodada é confiável, o fingerprint avalia a coerência do comportamento acumulado ao longo de múltiplas rodadas.

OPC UA é o protocolo de comunicação utilizado para acessar a representação lógica do processo. Em um servidor OPC UA, as variáveis são organizadas em uma árvore de objetos e nós. Um cliente navega nessa árvore, identifica o nó de uma variável e lê seu valor. No protótipo, temperatura, pressão e rotação são expostas pelo serviço SCADA local. O comparador associa cada nó lógico ao sensor correspondente e calcula a diferença entre o valor lido e o estado físico consensado.

A Figura 2, detalha esse acesso, onde na parte inferior da figura aparece a árvore do processo, formada por planta, unidades, controlador e sensores. No centro está o Edge Gateway atuando como cliente OPC UA, e na parte superior estão o SCADA, o banco de dados e as estações de operação. A seta vertical indica que o Edge Gateway consulta o domínio lógico por uma conexão OPC UA, sem substituir o caminho usado pelo operador.




Figura 2. Integração conceitual do Edge Gateway ao domínio lógico do SCADA por meio de OPC UA. Fonte: elaboração do autor para este projeto de pesquisa.

A Figura 2 é uma visão conceitual do acesso OPC UA e não uma afirmação de que existe um SCADA industrial físico no experimento. Na execução apresentada neste documento, o servidor SCADA é local e simulado, mas expõe as três variáveis por uma implementação real de OPC UA. A figura serve para explicar onde a leitura lógica se encontra no fluxo e por que ela é diferente da leitura física paralela.

## II-B. Literatura relacionada

Niedermaier, Kreimel e Golling [2] apresentam um IDS para dispositivos industriais de borda com poucos recursos. Nesse trabalho, a detecção de intrusões é realizada pela análise do tráfego da rede e dos intervalos de tempo entre as comunicações, permitindo identificar desvios do comportamento esperado. Nascimento [3] discute a combinação de Edge Computing e aprendizado de máquina para IDS. Spadaccino

e Cuomo [17] complementam essa discussão ao apresentar as oportunidades e os desafios do uso de IDS em IoT com processamento na borda, incluindo técnicas de detecção baseadas em anomalias. Esses trabalhos mostram a utilidade de aproximar o IDS do processo, mas analisam informações que já chegaram ao ambiente digital, eles não acrescentam uma leitura física paralela antes do PLC.

Na área distribuída, Nascimento apresenta uma arquitetura de IDS baseada em aprendizado federado [4], enquanto Olanrewaju-George e Pranggono [5] combinam modelos supervisionados e não supervisionados em uma solução federada para IoT. Em publicação mais recente, Anwer et al. [16] combinam CNN-Bi-LSTM e aprendizado federado nos datasets X-IIoTID, WUSTL-IIoT e Edge-IIoTset. Essas propostas distribuem treinamento ou detecção, mas não usam o consenso para decidir se uma observação física deve ser aceita antes de alimentar o modelo.

Blanchard et al. [6] explicam por que participantes que enviam informação arbitrária precisam fazer parte do modelo de ameaça. Buchman descreve a base de replicação tolerante a falhas que originou a família Tendermint, usada como referência técnica para o CometBFT [7]. Neste protótipo, o protocolo distribuído não treina um modelo federado, ele registra a rodada, enquanto a aplicação ABCI calcula compatibilidade, score, exclusões e quórum sobre as leituras físicas.

No eixo temporal, Gulzar e Mustafa [14] avaliam RNN, LSTM e Bi-LSTM com atenção nos datasets SWaT, WADI e GHL. Catillo, Pecchia e Villano [15] combinam autoencoder, score por ponto e janela deslizante para detectar anomalias coletivas em séries multivariadas. Esses dois artigos de 2025 sustentam o uso de contexto temporal, mas partem de séries digitais já disponíveis ao detector. A diferença deste trabalho está em controlar quais estados podem entrar no histórico usado pelo fingerprint. A Tabela I apresenta a comparação entre os trabalhos relacionados.

*Tabela I. Posicionamento da proposta em relação aos trabalhos relacionados.*

| Abordagem                                        | Edge/IIoT | Validação distribuída | Fonte física paralela | Comp. físico x SCADA | Fingerprint temporal |
|--------------------------------------------------|-----------|-----------------------|-----------------------|----------------------|----------------------|
| IDS industrial baseado em rede [1]-[3]           | Parcial   | Não                   | Não                   | Não                  | Parcial              |
| IDS em Edge Computing [2], [3]                   | Sim       | Parcial               | Não                   | Não                  | Parcial              |
| Aprendizado federado para IDS [4], [5], [16]     | Sim       | Parcial               | Não                   | Não                  | Sim                  |
| Tolerância bizantina em ML/distribuição [6], [7] | Parcial   | Sim                   | Não                   | Não                  | Não                  |
| Proposta deste projeto de pesquisa               | Sim       | Sim                   | Sim                   | Sim                  | Sim                  |

A comparação mostra a lacuna investigada: os trabalhos analisados oferecem mecanismos úteis de detecção, distribuição, tolerância a falhas ou aprendizado temporal, mas não foi identificada neles a combinação completa de uma observação anterior ao PLC com a verificação explícita do valor apresentado pelo SCADA.

### III. Arquitetura Proposta

A arquitetura proposta acrescenta um caminho de observação ao sistema industrial existente. Ela não substitui o PLC, o SCADA ou a lógica de controle. Um Edge Gateway é o serviço de borda que recebe a cópia da leitura e participa da validação. O caminho paralelo é dividido em cinco etapas: (1) observar o sinal de campo; (2) coletar e compartilhar as leituras; (3) formar um estado físico consensado; (4) comparar esse estado com o SCADA; e (5) armazenar os estados aceitos e gerar o fingerprint temporal.

Como mostra a Figura 3, os componentes foram separados por zonas, conforme sua função. Na Zone 4 estão sensores e divisores de sinal. Na Zone 3, três Edge Gateways compartilham observações e participam da validação distribuída, o comparador também recebe a leitura do SCADA. Na Zone 2 estão o PLC, a rede e o SCADA. Na Zone 1, os registros aceitos são armazenados e utilizados pelo modelo temporal, que pode emitir alertas. As setas da imagem (em cinza) distinguem o caminho industrial existente, dos sensores ao PLC e ao SCADA, e o caminho paralelo (em vermelho), dos sensores aos Edge Gateways, ao consenso, à comparação e ao fingerprint.




Figura 3. Arquitetura proposta com quatro zonas e os caminhos industrial e paralelo. Fonte: elaboração do autor para este projeto de pesquisa.

Na Figura 3, a Zone 4 representa a camada física e de campo, formada pelos sensores, splitters e pelas ligações com o PLC e os Edge Gateways. Nessa camada, HART e Profibus PA são os protocolos mais utilizados na comunicação com instrumentos industriais. O HART combina o sinal analógico de 4 a 20 mA com informações digitais e diagnósticos do instrumento, enquanto o Profibus PA utiliza um barramento de comunicação digital. Para o protótipo, foi escolhido somente o HART, pois sua utilização sobre o loop de 4 a 20 mA e os dados de diagnóstico são a maneira mais adequada de representar sistemas industriais legados. Essa característica também permite manter o envio tradicional ao PLC e, por meio de um splitter compatível, fornecer uma leitura paralela aos Edge Gateways. O Profibus PA não foi adotado porque exigiria a representação de uma infraestrutura de barramento digital e de outra forma de aquisição dos dados, aumentando a complexidade do protótipo sem modificar o objetivo do experimento. No ambiente implementado, esse funcionamento é representado por correntes simuladas de 4 a 20 mA e por dados de diagnóstico baseados nas informações fornecidas pelo HART. O objetivo não é comparar os protocolos de campo, mas avaliar se a leitura paralela pode ser validada pelo consenso e comparada com os dados obtidos do SCADA. Por isso, o HART fornece os elementos necessários para realizar essa avaliação.

No lado lógico, a arquitetura admite OPC Unified Architecture (OPC UA) ou outro protocolo industrial. O protótipo usa OPC UA: o serviço SCADA é simulado, mas a comunicação local usa uma implementação real do protocolo. Essa separação permite testar a comparação físico-lógica sem depender de um fabricante específico.

A Tabela II apresenta as cinco etapas. Cada linha identifica o dado recebido, a decisão tomada e o resultado que segue para a próxima etapa.

Tabela II. Entradas, decisões e saídas das cinco etapas da arquitetura.

| Etapa                    | Entrada              | Processamento ou decisão                                                   | Saída                                     |
|--------------------------|----------------------|----------------------------------------------------------------------------|-------------------------------------------|
| 1. Observação paralela   | Sinal do sensor      | Obter uma cópia sem alterar a entrada do PLC                               | Leitura física local                      |
| 2. Coleta no Edge        | Leitura física local | Acrescentar tempo, unidade, corrente e diagnósticos; compartilhar por MQTT | Visão das leituras dos três Edge Gateways |
| 3. Validação distribuída | Três observações     | Calcular distância, score, compatibilidade, exclusões e quórum             | Estado físico consensado ou bloqueio      |

| Etapa                      | Entrada                        | Processamento ou decisão                                        | Saída                            |
|----------------------------|--------------------------------|-----------------------------------------------------------------|----------------------------------|
| 4. Comparação com SCADA    | Estado consensado e nós OPC UA | Aplicar diferença absoluta e tolerância por sensor              | Comparação aceita ou divergência |
| 5. Histórico e fingerprint | Estado aceito                  | Persistir artefato, formar janelas e executar o modelo temporal | Dataset, classificação e alerta  |

A quinta etapa é detalhada na Figura 4. O processamento temporal ocorre no bloco ‘Modelo de Deep Learning (LSTM)’. Antes de entrar no modelo, os dados físicos validados e seus dados de contexto são colocados em ordem cronológica e agrupados em janelas formadas por leituras consecutivas. O modelo analisa essas janelas para identificar como as grandezas do equipamento variam em conjunto ao longo do tempo. Esse comportamento forma o fingerprint físico-operacional e permite identificar uma anomalia quando uma nova janela apresenta um padrão diferente do esperado. Na versão atual do protótipo, as grandezas utilizadas são temperatura, pressão e rotação.




Figura 4. Formação conceitual do fingerprint a partir de uma série multivariada do equipamento. Fonte: elaboração do autor para este projeto de pesquisa.

Na Figura 4, a nuvem representa a etapa de processamento e armazenamento, e não obriga o uso de um provedor de nuvem pública. O ponto importante é a ordem: dados aceitos formam um histórico, o modelo aprende relações temporais e uma mudança do padrão pode gerar alerta. No protótipo, o MinIO, como apresentado na Zone 1 da figura 3, armazena os artefatos e os modelos LSTM ou GRU recebem as janelas geradas a partir desse histórico.

## IV. Protótipo Acadêmico Implementado

O protótipo desenvolvido até este momento implementa as cinco etapas, descritas na Tabela II, em um ambiente controlado. O compressor, os sensores, o PLC e o conteúdo do SCADA são simulados para permitir repetição dos testes. Os serviços Python, o broker MQTT Mosquitto, a rede CometBFT, a interface Application Blockchain Interface (ABCI) em Go, o armazenamento de objetos MinIO, o cliente e servidor OPC UA locais e os modelos Keras/Torch funcionam com suas tecnologias reais.

A Figura 5 apresenta o pipeline de processamento para um equipamento compressor. O compressor gera valores de temperatura, pressão e rotação. Os três Edge Gateways são responsáveis por construir mensagens estruturadas, chamadas de payloads. Cada Edge Gateway publica seu próprio payload no broker MQTT e recebe, por meio desse mesmo broker, os payloads publicados pelos outros dois Edge Gateways. Dessa forma, os dados são trocados entre os três Edge Gateways, com o broker MQTT intermediando a comunicação. CometBFT registra a rodada e a aplicação ABCI calcula compatibilidade, score, exclusões, quórum e estado consensuado. O pipeline realiza duas verificações antes do armazenamento. Na primeira, a aplicação ABCI analisa as leituras, exclui os valores incompatíveis e verifica se os Edge Gateways restantes formam quórum para produzir um estado físico consensuado. Na segunda, o comparador verifica, para cada sensor, se a diferença entre o valor consensuado e o valor informado pelo SCADA permanece dentro da tolerância definida. Quando existe quórum e não há divergência acima dessa

tolerância, o MinIO armazena o artefato e o gerador de dataset cria as janelas utilizadas pelo fingerprint. Após o consenso, o resultado é enviado de forma assíncrona ao Cloud Bucket, onde passa a compor o histórico utilizado na geração do fingerprint físico-operacional. Paralelamente, o comparador físico-lógico confronta o valor consensuado com o valor informado pelo SCADA. Quando a diferença ultrapassa a tolerância definida, o sistema gera um alerta e registra a divergência, sem interromper o armazenamento dos dados nem o processamento posterior pelo modelo.



Figura 5. Pipeline executado no protótipo, da simulação do processo à persistência e ao fingerprint. Fonte: elaboração do autor com base na implementação do protótipo.

A Tabela III identifica o papel de cada componente e evita confundir o que é simulado com o que é executado. A simulação representa o ambiente acadêmico, os componentes de comunicação, consenso, persistência e aprendizado produzem registros auditáveis.

Tabela III. Componentes do protótipo acadêmico.

| Componente                 | Tecnologia                | Natureza                        | Função no protótipo                                         |
|----------------------------|---------------------------|---------------------------------|-------------------------------------------------------------|
| Compressor, sensores e PLC | Simulador Python          | Simulado                        | Gerar temperatura, pressão, rotação e corrente de 4 a 20 mA |
| Edge Gateways (3)          | Serviços Python           | Software real                   | Coletar, enriquecer e compartilhar as leituras              |
| Mensageria                 | MQTT / Mosquitto          | Protocolo e broker reais        | Transportar mensagens publish/subscribe                     |
| Consenso e validação       | CometBFT + ABCI em Go     | Software real                   | Registrar a rodada e calcular score, quórum e estado        |
| SCADA                      | Serviço simulado + OPC UA | Dados simulados; protocolo real | Fornecer o valor lógico para comparação                     |
| Persistência               | MinIO                     | Software real                   | Armazenar somente artefatos aceitos                         |
| Fingerprint                | LSTM/GRU, Keras/Torch     | Software real                   | Avaliar sequências e gerar classificação                    |

#### IV-A. Mudança da definição conceitual para a implementação

A proposta inicial previa o uso de FABA/BBD para realizar a validação distribuída das leituras. Durante o desenvolvimento, decidiu-se utilizar CometBFT com uma aplicação ABCI. O FABA é um agregador de gradientes relativamente compacto. O CometBFT, como protocolo completo de replicação de máquina de estados, é internamente muito mais sofisticado. Porém, no protótipo, o FABA teria de ser adaptado para dados de sensores já o CometBFT entrega esses mecanismos em software executável. Portanto a complexidade de engenharia para obter o mesmo resultado no protótipo foi menor usando o CometBFT. Além disso, seria necessário desenvolver outras funções para organizar, registrar e acompanhar cada rodada. Isso deixaria a implementação mais complexa, sem mudar o resultado esperado nesta etapa: verificar as leituras dos Edge Gateways, excluir valores incompatíveis, confirmar o quórum e produzir um estado físico consensuado. Por esse motivo, o CometBFT foi escolhido como uma solução mais simples e adequada para o protótipo. Ele organiza e confirma as rodadas de consenso, além de registrar informações como height e hash (height: número sequencial da rodada registrada, hash: código único que identifica e

comprova a integridade do registro). A aplicação ABCI executa as regras do projeto: compara as leituras, calcula os scores (pontuação que indica o grau de compatibilidade de cada leitura em relação às demais), exclui valores incompatíveis, verifica o quórum e produz o estado consensuado.

#### IV-B. Construção do estado físico simulado

Como o protótipo não está conectado a um compressor real, foi criado um simulador para produzir os dados necessários aos testes. O objetivo dessa simulação não é reproduzir com precisão um modelo específico de compressor, mas gerar valores coerentes para avaliar as principais etapas do projeto: leitura pelos Edge Gateways, consenso, comparação com o SCADA, armazenamento e geração do fingerprint.

No simulador, a carga do compressor varia de 0% a 100%. A partir dessa carga, são calculados valores de temperatura entre 48 e 95 graus Celsius, pressão entre 1,8 e 8,5 bar e rotação entre 1.200 e 4.200 rpm. Esses limites foram definidos como parâmetros do protótipo e podem ser alterados na configuração do simulador.

Essas três faixas foram utilizadas para verificar se os valores escolhidos eram compatíveis com dados de compressores reais. A base MetroPT-3 contém leituras reais de temperatura e pressão de um compressor e registra condições de operação próximas de 7 e 8,2 bar [18]. Um catálogo da Danfoss apresenta compressores com rotação entre 1.600 e 4.500 rpm [19], enquanto um documento da Atlas Copco utiliza 95 graus Celsius como uma referência de temperatura de saída do compressor [20]. Portanto, as fontes mostram que os valores utilizados são plausíveis, mas os limites exatos foram escolhidos para a simulação e não representam uma máquina industrial específica.

Os dados são atualizados por ciclos de leitura. Quando a carga do compressor é alterada, a leitura que já foi produzida não muda. A nova carga passa a ser considerada na leitura seguinte. O simulador também acrescenta pequenas oscilações ao longo dos ciclos para evitar que temperatura, pressão e rotação formem linhas perfeitamente retas ou mudem exatamente da mesma forma. Essas oscilações apenas tornam os dados simulados menos artificiais.

Além disso, cada leitura recebe uma pequena variação aleatória, representando as oscilações que podem ocorrer em sensores e processos reais. A intensidade dessa variação aumenta conforme a temperatura. Para realizar esse cálculo, a temperatura é convertida para um valor entre 0 e 1:

$$rT = (\text{temperatura} - 48) / (95 - 48)$$

Nesse cálculo,  $rT$  igual a 0 representa a temperatura mínima de 48 graus Celsius, enquanto  $rT$  igual a 1 representa a temperatura máxima de 95 graus Celsius. Essa conversão não representa o tempo necessário para a temperatura mudar. Ela serve somente para facilitar o cálculo da intensidade da variação aleatória.

A intensidade é calculada da seguinte forma:

$$\text{nivel\_ruído} = 0,15 + (rT \times 0,85 \times \text{multiplicador})$$

O valor 0,15 garante que exista uma pequena variação mesmo em temperaturas baixas. O valor 0,85 faz essa variação aumentar junto com a temperatura. O multiplicador é um parâmetro de teste: o valor 1 mantém a configuração normal, valores maiores aumentam a variação e valores menores a reduzem.

Para definir se a leitura será aumentada ou diminuída, o simulador sorteia um número entre -1 e 1. Um número negativo reduz o valor, enquanto um número positivo o aumenta. Esse número é multiplicado por um limite próprio de cada sensor:

$$\text{temperatura} = \text{temperatura\_esperada} + (\text{numero\_aleatorio} \times 5 \times \text{nivel\_ruído})$$

$$\text{pressao} = \text{pressao\_esperada} + (\text{numero\_aleatorio} \times 0,35 \times \text{nivel\_ruído})$$

$$\text{rotacao} = \text{rotacao\_esperada} + (\text{numero\_aleatorio} \times 60 \times \text{nivel\_ruído})$$

Os valores 5, 0,35 e 60 também são parâmetros definidos no protótipo. Eles limitam a variação aplicada a cada grandeza para que ela seja visível, mas não domine o comportamento geral da simulação. Quando o nível de ruído é igual a 1, a variação máxima é de 5 graus Celsius para temperatura, 0,35 bar para pressão e 60 rpm para rotação.

O gerador de números aleatórios pode começar sempre com o mesmo valor inicial, chamado de semente. Quando a mesma semente é utilizada, o simulador repete a mesma sequência de variações aleatórias. Isso permite executar novamente o experimento nas mesmas condições e conferir os resultados obtidos.

Depois de gerar a leitura, o simulador calcula o percentual correspondente dentro da faixa do sensor:

$$\text{percentual} = 100 \times (\text{valor} - \text{minimo}) / (\text{maximo} - \text{minimo})$$

Esse percentual é convertido em corrente de 4 a 20 mA:

$$\text{corrente\_mA} = 4 + (16 \times \text{percentual} / 100)$$

O número 16 corresponde à diferença entre 20 e 4 mA. Dessa forma, o início da faixa produz 4 mA e o final produz 20 mA. Essa conversão segue o funcionamento do loop de corrente utilizado por instrumentos HART [21].

Por fim, o payload de cada sensor possui nove atributos. Três representam a medição: valor do processo, percentual da faixa e corrente de 4 a 20 mA. Outros três descrevem o comportamento da leitura: nível de ruído, diferença para a leitura anterior e score local de estabilidade. Os três últimos indicam condições do sensor: falha de campo, saturação da corrente e partida a frio. O score local de estabilidade mostra se a leitura está variando pouco ou muito e não é o mesmo score utilizado posteriormente no consenso. Como o protótipo utiliza três sensores, cada um com nove atributos, cada estado físico possui 27 atributos.

#### IV-C. Score, quórum e comparação com o SCADA

Depois de receber as leituras dos três Edge Gateways, a aplicação ABCI compara os valores apresentados por eles. Essa comparação não representa a distância física entre os equipamentos na planta. Ela indica apenas o quanto os valores de temperatura, pressão e rotação informados por um Edge Gateway diferem dos valores informados pelos demais.

Como temperatura, pressão e rotação utilizam unidades e escalas muito diferentes, suas diferenças não podem ser comparadas diretamente. Por exemplo, uma diferença de 100 rpm produziria um número muito maior do que uma diferença de 1 bar, mesmo que ambas fossem pequenas dentro de suas respectivas faixas. Para evitar que uma grandeza tenha mais influência somente por utilizar números maiores, o protótipo calcula um índice de divergência entre dois Edge Gateways, chamados A e B:

$$D(A,B) = (\text{diferenca\_temperatura} / 20 + \text{diferenca\_pressao} / 3 + \text{diferenca\_rotacao} / 600) / 3$$

Nesse cálculo, cada diferença é considerada em valor absoluto. Portanto, não importa qual Edge Gateway apresentou o maior ou o menor valor, mas somente o tamanho da diferença entre eles. Os números 20, 3 e 600 são escalas de referência definidas no protótipo para temperatura, pressão e rotação. Assim, uma diferença de 20 graus Celsius, 3 bar ou 600 rpm acrescenta o mesmo valor, igual a 1, antes do cálculo da média. A divisão final por 3 representa a média das três grandezas, fazendo com que temperatura, pressão e rotação tenham o mesmo peso.

Essas escalas não correspondem às faixas completas dos sensores apresentadas na Seção IV-B, nem à exatidão de instrumentos comerciais. Elas são parâmetros configuráveis criados para permitir a comparação entre grandezas diferentes no ambiente de laboratório. Em uma aplicação industrial real, eles deverão ser ajustados de acordo com os instrumentos e com o comportamento esperado do processo.

Quanto menor for o valor de  $D(A,B)$ , mais semelhantes são as leituras. Se os dois Edge Gateways apresentarem exatamente os mesmos valores,  $D(A,B)$  será igual a zero. Por exemplo, diferenças de 2 graus Celsius, 0,1 bar e 30 rpm resultam em um índice de aproximadamente 0,061:

$$D(A,B) = (2 / 20 + 0,1 / 3 + 30 / 600) / 3 = 0,061$$

Para cada Edge Gateway, o protótipo calcula a média dos índices obtidos na comparação com os outros participantes. Essa média é chamada neste texto de desvio médio. Depois, o score de confiança é calculado da seguinte forma:

$$\text{score} = 1 / (1 + \text{desvio\_medio})$$

O score não representa uma probabilidade. Ele apenas resume o grau de compatibilidade da leitura com as demais. Quando não existe diferença, o desvio médio é zero e o score é igual a 1,000. Conforme as diferenças aumentam, o score diminui e se aproxima de zero.

Dois Edge Gateways são considerados compatíveis quando o índice  $D(A,B)$  é menor ou igual a 0,35. Esse valor também é um parâmetro de laboratório definido para o protótipo. Ele foi utilizado para separar leituras consideradas próximas das leituras alteradas nos testes, mas não foi obtido pela calibração de um instrumento real. Quando as três grandezas contribuem igualmente para o cálculo, o limite 0,35 corresponde a diferenças de 7 graus Celsius, 1,05 bar e 210 rpm.

O quórum representa a quantidade mínima de participantes necessária para aceitar um estado físico. Ele é calculado pela maioria dos participantes. Como o protótipo utiliza três Edge Gateways, são necessários pelo menos dois participantes. Para cada Edge Gateway, o sistema soma sua própria leitura ao número de participantes compatíveis. Se esse total for menor que dois, o Edge Gateway é excluído daquela rodada.

Depois das exclusões, se pelo menos dois Edge Gateways permanecerem, o estado físico consensuado é calculado pela média das leituras válidas de temperatura, pressão e rotação. Se restarem menos de dois participantes, não existe quórum e aquela rodada não produz um estado físico consensuado. Isso não interrompe permanentemente o sistema, pois uma nova tentativa é realizada no ciclo seguinte.

Quando o consenso é concluído, o estado físico é comparado com os valores apresentados pelo SCADA.

Para cada sensor, o comparador calcula a diferença absoluta:

$$\text{diferenca\_absoluta} = \text{valor\_fisico} - \text{valor\_SCADA}$$

As tolerâncias utilizadas são 2 graus Celsius para temperatura, 0,35 bar para pressão e 120 rpm para rotação. Esses valores também são parâmetros configuráveis de laboratório. Em relação às faixas apresentadas na Seção IV-B, eles correspondem a aproximadamente 4,3% da faixa de temperatura, 5,2% da faixa de pressão e 4% da faixa de rotação. Essas porcentagens ajudam a mostrar a proporção dos limites utilizados, mas não representam o critério original de escolha. O protótipo ainda não possui calibração baseada em instrumentos ou em um compressor industrial específico.

A comparação é considerada compatível quando todas as diferenças permanecem dentro de suas tolerâncias. Se qualquer diferença superar o respectivo limite, o indicador de divergência com o SCADA torna-se verdadeiro e o sistema gera um alerta.

Conforme a arquitetura apresentada na Figura 2, o comparador atua como cliente OPC UA e lê os valores de temperatura, pressão e rotação disponibilizados pelo SCADA simulado. A comparação com o SCADA ocorre em paralelo ao envio do estado consensuado para o Cloud Bucket. Quando uma divergência é encontrada, ela é registrada e gera um alerta.

#### **IV-D. Ciclo operacional e organização temporal**

Cada ciclo operacional corresponde a uma passagem completa pelas etapas apresentadas na Figura 5. Primeiro, o simulador atualiza os valores dos sensores. Em seguida, os Edge Gateways coletam esses valores e enviam suas observações por MQTT para o consenso. Após o consenso, o estado físico obtido é comparado com o SCADA e encaminhado para armazenamento e para a atualização do fingerprint.

Nos testes apresentados neste trabalho, o intervalo entre os ciclos foi configurado, em alguns casos sessenta segundos em outros apenas dois segundos. Esse intervalo reduzido foi utilizado apenas para acelerar a demonstração e permitir a obtenção dos resultados em menos tempo. Portanto, ele representa a velocidade de execução do protótipo durante os testes, e não a duração do processo industrial simulado.

Além desse intervalo, cada rodada de consenso registra um horário de início e um horário de término. O término corresponde ao momento da última aquisição realizada pelos Edge Gateways, enquanto o início é definido como 60 segundos antes. Esses horários formam a janela nominal de consenso e servem para identificar temporalmente a rodada.

A janela de entrada do modelo é um terceiro conceito. Ela é formada pelo agrupamento cronológico de artefatos que atenderam às regras de validade do consenso, criando a sequência de dados analisada pela LSTM. Portanto, o intervalo de dois segundos controla a velocidade dos testes, a janela de 60 segundos identifica a rodada de consenso e a janela do modelo organiza os registros usados no fingerprint. A transformação desses registros no tensor (conjunto de números organizado em várias dimensões) temporal é apresentada na Seção VI-B.

### **V. Cenários de Validação**

Três cenários demonstram os principais conceitos de validação do pipeline. Como mostra a Figura 6, o consenso verifica primeiro se existe quórum. Em seguida, o comparador verifica se o SCADA representa o mesmo estado. Somente o caminho verde armazena o artefato. Os caminhos vermelho e amarelo bloqueiam as etapas posteriores e registram o motivo.



Figura 6. Fluxo dos cenários normal, quorum\_loss e scada\_divergence. Fonte: elaboração do autor com base nas execuções do protótipo.

A Tabela IV detalha o que foi alterado, os scores observados e o resultado de cada execução.

Tabela IV. Cenários executados e resultados observados.

| Cenário          | Condição e leituras                                                                               | Scores E1 / E2 / E3   | Resultado demonstrado                                                            |
|------------------|---------------------------------------------------------------------------------------------------|-----------------------|----------------------------------------------------------------------------------|
| normal           | Leituras compatíveis. Exemplo aceito: 76,835 °C; 6,075 bar; 3.186,012 rpm.                        | 1,000 / 1,000 / 1,000 | Quórum 3/3; SCADA compatível; artefato persistido                                |
| quorum_loss      | E1 sem alteração; E2 recebe +40 °C, +3,4 bar e +1.490 rpm; E3 recebe -60 °C, -5 bar e -2.300 rpm. | 0,298 / 0,233 / 0,210 | Nenhum par compatível; três exclusões; sem estado; etapas posteriores bloqueadas |
| scada_divergence | Consenso físico compatível. SCADA recebe +6 °C, +0,6 bar e +300 rpm.                              | 1,000 / 1,000 / 1,000 | Quórum 3/3; três diferenças acima da tolerância; persistência bloqueada          |

No cenário quorum\_loss, o Edge Gateway 1 não recebe alteração, mas também é excluído porque fica isolado das duas visões modificadas. Isso mostra que o score representa concordância entre participantes, e não uma prova individual de que o sensor está correto. No cenário scada\_divergence, os scores permanecem 1,000 porque os três Edge Gateways concordam entre si, o bloqueio acontece somente na comparação com o SCADA.

Os cenários cobrem aceitação do estado válido, recusa sem quórum e detecção de alteração no domínio lógico. Repetição de leituras, congelamento, mudança gradual e exclusão de um único Edge Gateway serão incluídos na continuidade deste trabalho para ampliar a cobertura do modelo de ameaça.

## VI. Resultados

### VI-A. Artefatos do pipeline

As execuções do protótipo produziram registros com identificação da rodada, height e hash, que é o identificador criptográfico do consenso, participantes, quórum, scores, exclusões, estado físico, comparação com o SCADA e decisão de persistência. Cada registro JSON persistido é chamado de artefato. No cenário normal, o artefato foi gravado no MiniIO. Em cenários bloqueados (onde a validação falhou), nenhum artefato válido foi gravado, evitando que dados sem quórum ou divergentes alimentem o dataset.

A Tabela V apresenta uma comparação registrada no cenário normal. Os valores são iguais por construção, pois o SCADA simulado reproduz o estado físico quando nenhuma divergência é injetada. As tolerâncias permanecem visíveis para mostrar a regra que seria aplicada se houvesse diferença.

*Tabela V. Comparação entre estado físico e SCADA no cenário normal.*

| Sensor      | Valor físico  | Valor SCADA   | Diferença | Tolerância  | Decisão |
|-------------|---------------|---------------|-----------|-------------|---------|
| Temperatura | 76,835 °C     | 76,835 °C     | 0,000 °C  | 2,000 °C    | Aceito  |
| Pressão     | 6,075 bar     | 6,075 bar     | 0,000 bar | 0,350 bar   | Aceito  |
| Rotação     | 3.186,012 rpm | 3.186,012 rpm | 0,000 rpm | 120,000 rpm | Aceito  |

## VI-B. Transformação do estado em janela temporal

Na execução auditada em 23 de junho de 2026, o pipeline encontrou 14 artefatos elegíveis armazenados no cenário normal. Cada artefato representa um estado físico que passou pelas etapas de consenso e validação previstas no protótipo. Portanto, o número 14 não foi escolhido como configuração ou quantidade ideal: ele corresponde ao total de estados válidos acumulados naquela execução.

Para formar uma entrada temporal, os artefatos são ordenados pelo horário de encerramento da rodada e agrupados em sequências. O comprimento da sequência foi configurado como 2. Ele foi mantido nesta demonstração porque dois estados constituem a menor sequência capaz de representar uma mudança temporal: o primeiro mostra a condição anterior e o segundo mostra a condição seguinte. Uma sequência com apenas um estado não permitiria observar essa transição. Como o histórico disponível era pequeno, utilizar sequências maiores também reduziria ainda mais a quantidade de janelas geradas.

O passo de deslocamento foi configurado como 1. Isso significa que, após formar uma janela, o gerador avança apenas um artefato para formar a próxima. Dessa forma, a primeira janela contém os artefatos 1 e 2, a segunda contém os artefatos 2 e 3, e assim sucessivamente, até a última janela, formada pelos artefatos 13 e 14. A reutilização de um artefato entre janelas permite aproveitar todas as transições existentes no pequeno histórico. Por esse motivo, os 14 artefatos produzem 13 janelas:

$$\text{numero\_de\_janelas} = ((14 - 2) / 1) + 1 = 13$$

Os artefatos são consecutivos na lista ordenada, mas o gerador atual não exige que o intervalo de tempo entre eles seja sempre igual. Ele considera apenas a ordem cronológica dos registros. A verificação de um intervalo máximo entre estados deverá ser acrescentada em uma etapa posterior do desenvolvimento.

Cada estado possui 27 atributos. Esse número resulta dos três sensores utilizados pelo protótipo, temperatura, pressão e rotação, cada um representado pelos nove atributos descritos na Seção IV-B. Portanto:

$$3 \text{ sensores} \times 9 \text{ atributos por sensor} = 27 \text{ atributos por estado}$$

Com 13 janelas, dois estados por janela e 27 atributos em cada estado, o conjunto possui a forma [13, 2, 27]. O primeiro número representa a quantidade de janelas, o segundo representa os dois momentos consecutivos de cada janela e o terceiro representa os atributos observados em cada momento.

O pipeline também verifica se o conjunto alcançou dois pisos internos: pelo menos 30 artefatos elegíveis e pelo menos 20 janelas. As duas verificações possuem funções diferentes. O primeiro valor avalia a quantidade de estados válidos disponíveis antes do agrupamento, o segundo avalia quantos exemplos temporais foram produzidos depois da formação das janelas.

Os valores exatos de 30 artefatos e 20 janelas são configurações iniciais do protótipo. Sua função é apenas impedir que uma execução pequena seja apresentada como um conjunto já adequado para avaliação do modelo. Mesmo que esses pisos sejam alcançados, ainda será necessário validar o volume e os parâmetros com um histórico físico-operacional representativo.

*Tabela VI. Dataset físico-operacional gerado pelo protótipo.*

| Artefatos | Janelas | Sequence length | Stride | Atributos | Forma do tensor | Rótulo atual |
|-----------|---------|-----------------|--------|-----------|-----------------|--------------|
| 14        | 13      | 2               | 1      | 27        | [13, 2, 27]     | normal       |

Os 27 atributos resultam dos nove campos descritos para cada um dos três sensores: temperatura, pressão e rotação. O manifesto é um arquivo JSON que registra as informações do dataset gerado, como os artefatos utilizados, a quantidade de janelas, o comprimento das sequências e o formato do tensor. O arquivo NPZ é um arquivo compactado do NumPy que armazena os dados numéricos das janelas temporais. A demonstração foi realizada carregando esse arquivo e inspecionando a forma do vetor

feature\_tensor. Como apresentado na Tabela VI, o resultado foi [13, 2, 27], correspondente a 13 janelas, dois estados consecutivos por janela e 27 atributos por estado. Essa organização segue o formato tridimensional (amostras, instantes e atributos) utilizado como entrada por modelos temporais como LSTM e GRU.

### VI-C. Avaliação preliminar com ADFA-LD

Como o dataset próprio ainda contém somente a classe normal, o dataset ADFA-LD [8] foi usado para medir a etapa supervisionada do fingerprint. O conjunto contém 5.951 traços de chamadas de sistema Linux, sendo 5.205 normais e 746 de ataque em cinco famílias. O uso deste dataset serviu para validar se o pipeline de sequências, treinamento e classificação produz métricas objetivas, enquanto o dataset próprio é ampliado.

O adaptador gerou 8.172 janelas para comprimento 80: 5.205 normais e 2.967 de ataque. A divisão estratificada, com semente aleatória 42, produziu 6.538 janelas de treino e 1.634 de teste. Foram comparadas LSTM e GRU com comprimentos 50, 80 e 120, representando contextos curtos, médios e longos dentro do experimento. Todas as configurações receberam o mesmo limite de 18 épocas para permitir comparação direta. O modelo usa uma camada de representação numérica, chamada embedding, com dimensão 64, uma camada recorrente com 64 unidades, dropout 0,3 para regularização, Adam com taxa 0,001, lote 256 e entropia cruzada com pesos inversos à frequência das classes. Os números correspondem a uma execução por configuração.

A Tabela VII apresenta os resultados da classificação binárias (duas classes: normal e ataque). Foram avaliadas seis configurações: os modelos LSTM e GRU, cada um com sequências de 50, 80 e 120 chamadas de sistema. A apresentação de todas as combinações evita relatar somente o melhor resultado e permite observar o efeito do tipo de modelo e do comprimento da sequência.

Tabela VII. Resultados binários no ADFA-LD.

| Modelo | Seq. | Épocas | Macro F1 | Acurácia | Macro precisão | Macro recall |
|--------|------|--------|----------|----------|----------------|--------------|
| LSTM   | 80   | 18     | 0,9187   | 0,9229   | 0,9116         | 0,9304       |
| LSTM   | 120  | 18     | 0,9165   | 0,9244   | 0,9098         | 0,9250       |
| GRU    | 120  | 18     | 0,9158   | 0,9238   | 0,9092         | 0,9241       |
| GRU    | 80   | 18     | 0,9120   | 0,9162   | 0,9046         | 0,9259       |
| LSTM   | 50   | 18     | 0,8910   | 0,8962   | 0,8843         | 0,9033       |
| GRU    | 50   | 18     | 0,8819   | 0,8871   | 0,8752         | 0,8961       |

O melhor resultado foi LSTM com sequência 80: macro F1 0,9187, acurácia 0,9229, macro precisão 0,9116 e macro recall 0,9304. A Tabela VIII mostra a o melhor modelo binário e permite calcular os erros sem deixar o resultado restrito a uma única métrica.

Tabela VIII. Melhor modelo binário.

| Classe real / prevista | Predito normal | Predito ataque |
|------------------------|----------------|----------------|
| Normal                 | 940            | 101            |
| Ataque                 | 25             | 568            |

O protótipo possui dois propósitos nesta etapa. O primeiro é demonstrar o funcionamento do caminho completo: obtenção do estado físico, consenso, comparação com o SCADA, armazenamento e formação das sequências temporais. O segundo é verificar se o classificador temporal consegue diferenciar sequências normais de sequências de ataque. Como o dataset físico-operacional próprio não permitiu diferenciar de forma consistente os cenários de replay e freeze do comportamento normal, por isso, a avaliação da classificação foi realizada separadamente com o ADFA-LD e será posteriormente ampliada para outros datasets. Portanto, este experimento não comprova ainda a detecção de ataques no compressor simulado, ele avalia apenas a etapa de treinamento e classificação do fingerprint.

No melhor experimento de classificação entre normal e ataque, o conjunto de teste continha 1.634 janelas: 1.041 normais e 593 de ataque. Esses totais podem ser conferidos na Tabela VIII: as 1.041 janelas normais correspondem a 940 classificadas corretamente como normais e 101 classificadas incorretamente como ataque. As 593 janelas de ataque correspondem a 568 ataques identificados corretamente e 25 classificados incorretamente como normais.

Assim, o modelo identificou 568 dos 593 ataques, o que corresponde a um recall de ataque de 0,9578, ou 95,78%. Os 25 ataques não identificados representam uma taxa de falso negativo de 0,0422, ou 4,22%. Entre as 1.041 janelas normais, 101 geraram falsos alarmes, resultando em uma taxa de falso positivo de

0,0970, ou 9,70%. Considerando as duas classes, o modelo acertou 1.508 das 1.634 janelas, produzindo a acurácia de 0,9229 e o macro F1 de 0,9187 apresentados na Tabela VII.

Uma segunda avaliação tentou classificar seis categorias: comportamento normal e cinco famílias de ataque. Nesse experimento separado, a melhor configuração foi novamente a LSTM com sequência 80, que obteve macro F1 de 0,5610 e acurácia de 0,7162. Esse resultado mostra que identificar a família específica do ataque foi mais difícil do que apenas distinguir entre normal e ataque. Por isso, a conclusão atual fica limitada à classificação entre essas duas classes.

#### VI-D. Relação entre os resultados

Os resultados das Tabelas IV e V avaliam decisões do caminho físico-lógico. A Tabela IV mostra que o score e o quórum separam concordância entre Edge Gateways de divergência no SCADA. A Tabela V mostra a comparação sensor a sensor depois do consenso. Portanto, o score não substitui a tolerância do SCADA: o primeiro mede concordância entre observadores físicos e a segunda mede diferença entre o estado aceito e a representação lógica.

A Tabela VI avalia a integração com o aprendizado. Seus 13 exemplos temporais não são usados para afirmar desempenho de classificação, eles demonstram que artefatos aceitos viram um tensor com a forma esperada. As Tabelas VII e VIII avaliam o classificador em um conjunto público rotulado e respondem a outra pergunta: se o modelo temporal consegue separar sequências normais e de ataque em um benchmark disponível.

A leitura conjunta evita uma conclusão incorreta. O macro F1 de 0,9187 não mede diretamente o cenário do compressor, e as 13 janelas do compressor não produzem o macro F1. O que está demonstrado nesta etapa é a união funcional das etapas e, separadamente, a capacidade preliminar do modelo temporal em dados rotulados. A etapa final aproximará essas duas evidências por meio de datasets industriais públicos e de um conjunto próprio maior e rotulado.

### VII. Discussão e Próximos Passos

Os resultados mostram um protótipo funcional. Dentro desse ambiente, o protótipo usa protocolos e tecnologias comumente utilizados no chão de fábrica, registra os scores e as decisões, impede a persistência de estados recusados e gera dados temporais para aprendizado.

O ADFA-LD fornece uma primeira métrica supervisionada, mas não é o único dataset previsto para ser utilizado. O dataset LID-DS 2021, mantido pelo grupo de sistemas de banco de dados da Universität Leipzig [9], é uma outra possibilidade. Goh et al. apresentam o dataset SWaT, criado para estudos de segurança em tratamento de água [10]. Ahmed, Palleti e Mathur descrevem o testbed WADI de distribuição de água [11]. Shin et al. apresentam o HAI, voltado a sistemas de controle industrial [12]. Morris e Gao disponibilizam conjuntos de tráfego de gasoduto e tanque [13]. Esses conjuntos serão comparados na etapa final para ampliar tipos de dados, ataques e modelos avaliados.

Essa ampliação também responde aos trabalhos recentes. Gulzar e Mustafa [14] usam SWaT, WADI e GHL para comparar modelos recorrentes, Catillo, Pecchia e Villano [15] avaliam anomalias coletivas com janelas temporais, Anwer et al. [16] comparam uma arquitetura federada em três datasets de IIoT. Neste trabalho, esses artigos não são citados apenas como uma lista: eles orientam três decisões futuras, respectivamente comparar mais de um modelo, observar ataques que se formam ao longo de uma janela e testar mais de um dataset público.

O dataset próprio também será ampliado e receberá rótulos dos cenários controlados. Serão registrados o modo de geração, os deslocamentos aplicados, o intervalo temporal e a decisão esperada. Isso permitirá relacionar cada rótulo ao mecanismo que o produziu, em vez de classificar uma janela como anômala sem explicar a origem da anomalia.

A Tabela IX organiza os passos que aumentam a força acadêmica dos resultados e conduzem à dissertação.

**Tabela IX. Continuidade prevista para a etapa final do Mestrado.**

| Atividade                                    | Jul | Ago | Set | Out | Nov | Dez |
|----------------------------------------------|-----|-----|-----|-----|-----|-----|
| A1. Consolidar e apresentar o Seminário      | X   |     |     |     |     |     |
| A2. Incluir LID-DS, SWaT, WADI, HAI e Morris |     | X   | X   | X   |     |     |

| Atividade                                           | Jul | Ago | Set | Out | Nov | Dez |
|-----------------------------------------------------|-----|-----|-----|-----|-----|-----|
| A3. Executar replay, freeze, drift e exclusão única |     |     | X   | X   |     |     |
| A4. Repetir treino por traço e múltiplas sementes   |     |     | X   | X   | X   |     |
| A5. Integrar e persistir o modelo selecionado       |     |     |     | X   | X   |     |
| A6. Produção textual e artigo                       |     |     |     | X   | X   | X   |
| A7. Escrita e defesa da dissertação                 |     |     |     |     | X   | X   |

## VIII. Artefatos e Publicações

Os artefatos desta etapa incluem o código do protótipo, os arquivos de configuração, os comandos e logs dos três cenários, os payloads de consenso e de comparação com o SCADA, os objetos persistidos no MinIO, o manifesto e o tensor do dataset próprio, as tabelas de resultados do ADFA-LD e a evidência da inferência online. Esses itens permitem conferir como cada resultado foi produzido. Até esta versão do Seminário, ainda não houve submissão formal de artigo, a produção textual está prevista na Tabela IX.

## IX. Considerações Finais

Este Seminário de Andamento apresentou um protótipo acadêmico funcional da Fonte de Verdade Física Paralela. O processo começa com uma cópia simulada do sinal do sensor, continua com a troca das observações por MQTT e a validação por CometBFT e ABCI, compara o estado consensado com os nós OPC UA do SCADA local e usa somente estados aceitos para persistência e formação do histórico temporal.

As execuções demonstraram três comportamentos: aceitação do cenário normal com score 1,000 nos três Edge Gateways, bloqueio da perda de quórum com scores 0,298, 0,233 e 0,210, e bloqueio da divergência do SCADA mesmo com score 1,000 entre os participantes. O protótipo também gerou 13 janelas com 27 atributos e obteve macro F1 0,9187 no melhor teste binário com ADFA-LD.

Esses resultados atendem ao objetivo desta etapa: demonstrar, em ambiente acadêmico controlado, que a arquitetura pode ser executada de ponta a ponta com tecnologias reais. A continuidade amplia datasets, cenários e repetições para produzir uma avaliação acadêmica mais abrangente no documento final.

## Referências

- [1] Botvinkin, P. V.; Kamaev, V. A.; Nefedova, I. S.; Finogeev, A. G.; Finogeev, E. A. "Analysis, classification and detection methods of attacks via wireless sensor networks in SCADA systems". Life Science Journal, 11(11s):384-388, 2014.
- [2] Niedermaier, M.; Kreimel, P.; Golling, M. "Efficient intrusion detection on low-performance industrial IoT edge node devices". IEEE Int. Conf. on Industrial Cyber-Physical Systems (ICPS), 2019.
- [3] do Nascimento, F. A. M. "Intrusion Detection System for IoT: Opportunities and Challenges Offered by Edge Computing and Machine Learning". Future Generation Computer Systems, Elsevier, 2019.
- [4] do Nascimento, F. A. M. "Decentralized Federated Learning-Based Intrusion Detection in IoT Systems". Tese de Doutorado, Escola Politécnica, PUCRS, 2023.
- [5] Olanrewaju-George, B.; Pranggono, B. "Federated learning-based intrusion detection system for the Internet of Things using unsupervised and supervised deep learning models". 2024.
- [6] Blanchard, P.; El Mhamdi, E. M.; Guerraoui, R.; Stainer, J. "Machine learning with adversaries: Byzantine tolerant gradient descent". NeurIPS, 2017.
- [7] Buchman, E. "Tendermint: Byzantine Fault Tolerance in the Age of Blockchains". Dissertação de Mestrado, University of Guelph, 2016. Base do CometBFT.
- [8] Creech, G.; Hu, J. "Generation of a New IDS Test Dataset: Time to Retire the KDD Collection". IEEE WCNC, 2013. Dataset ADFA-LD.
- [9] LID-DS 2021. Database Systems Group, Universität Leipzig.
- [10] Goh, J.; Adepu, S.; Junejo, K. N.; Mathur, A. "A Dataset to Support Research in the Design of Secure Water Treatment Systems (SWaT)". CRITIS, 2016.

- [11] Ahmed, C. M.; Palleti, V. R.; Mathur, A. P. "WADI: A Water Distribution Testbed for Research in the Design of Secure Cyber-Physical Systems". CySWATER, 2017.
- [12] Shin, H.-K.; Lee, W.; Yun, J.-H.; Kim, H. "HAI 1.0: HIL-based Augmented ICS Security Dataset". USENIX CSET, 2020.
- [13] Morris, T.; Gao, W. "Industrial Control System Traffic Data Sets for Intrusion Detection Research". ICCIP, 2014.
- [14] Gulzar, Q.; Mustafa, K. "Interdisciplinary framework for cyber-attacks and anomaly detection in industrial control systems using deep learning". Scientific Reports, v. 15, art. 26575, 2025. DOI: 10.1038/s41598-025-89650-5.
- [15] Catillo, M.; Pecchia, A.; Villano, U. "MultiCIDS: Anomaly-based collective intrusion detection by deep learning on IoT/CPS multivariate time series". Internet of Things, v. 30, art. 101519, 2025. DOI: 10.1016/j.iot.2025.101519.
- [16] Anwer, R. W.; Abrar, M.; Ullah, M.; Salam, A.; Ullah, F. "Advanced intrusion detection in the industrial Internet of Things using federated learning and LSTM models". Ad Hoc Networks, v. 178, art. 103991, 2025. DOI: 10.1016/j.adhoc.2025.103991.
- [17] Spadaccino, P.; Cuomo, F. "Intrusion detection systems for IoT: Opportunities and challenges offered by edge computing". *ITU Journal on Future and Evolving Technologies*, v. 3, n. 2, p. 408–420, 2022. DOI: 10.52953/WNVI5792.
- [18] N. Davari, B. Veloso, R. Ribeiro e J. Gama. MetroPT-3 Dataset. UCI Machine Learning Repository, 2021. DOI: 10.24432/C5VW3R. Disponível em: <https://archive.ics.uci.edu/dataset/791/metropt%2B3%2Bdataset>
- [19] Danfoss. Rotary Compressors - Variable Speed Compressors. Catálogo técnico, 2026. Disponível em: <https://assets.danfoss.com/documents/latest/595237/AN464543903088en-000401.pdf>
- [20] Atlas Copco. How to select the perfect air compressor oil? 2025. Disponível em: <https://www.atlascopco.com/en-us/compressors/air-compressor-blog/selection-criteria-compressor-oil>
- [21] FieldComm Group. HART 7 Device Variables Example. 2016. Disponível em: <https://support.fieldcommgroup.org/support/solutions/articles/8000029592-hart-7-device-variables-example>